DM3 : Épidémiologie

M2MSR 2023-2024

Groupe 11 - Julien ELICES-DIEZ

ju.diez@protonmail.com

2025-11-30

Table des matières

1 Data management ... 6
1.1 Composition initiale ... 6
1.1.a Valeurs aberrantes ... 6
1.1.b Valeurs manquantes ... 6
1.2 Recodage des variables ... 7
1.2.a Synthèse des catégories diagnostiques ... 7
1.2.b Synthèse des diagnostics et comorbidités ... 8
1.2.c Factorisation du niveau d'études ... 9
1.2.d Conversion des unités de mesures ... 9
1.2.e Calcul des délais et outcomes ... 9
1.2.f Classes d'âges ... 9
1.2.g Exclusions ... 10
1.2.h Gestion des valeurs aberrantes ... 11
1.3 Composition finale ... 11
2 Analyse descriptive univariée ... 13
3 Analyse descriptive bivariée ... 18
3.1 Mortalité à 30 jours ... 19
3.2 Cathétérisme droit ... 24
4 Score de propension ... 30
4.1 Imputation des données manquantes ... 31
4.2 Description du modèle ... 31
4.3 Performances du modèle ... 33
4.4 Appariement ... 34
5 Mortalité à 30 jours ... 36
6 Analyse de survie ... 37
7 Sans ajustement ... 39
8 Après ajustement ... 39
9 Conclusion ... 40

Énoncé

Ce devoir portait sur les données d'une **étude observationnelle** réalisée en unité de soins intensifs : Connors *et al.* (1996): The effectiveness of RHC in the initial care of critically ill patients. *J American Medical Association* 276:889-897.

L'objectif était de comparer **le risque de mortalité à 30 jours** entre les sujets ayant subi la pose d'une sonde de Swan-Ganz dans les 24h suivant l'admission en soins intensifs et les sujets n'ayant pas subi l'intervention.

La pose de sonde de Swan-Ganz était qualifiée pour la suite de **cathétérisme droit** (variable `rhc`).

Note

L'ensemble du code est divisé en 2 types de scripts :

- Préparation des données (`_setup.R`)
- Production des tableaux et figures (`tbl_*.R` ou `fig_*.R`)

Les paramètres et objets définis dans `_setup.R` sont injectés dans les scripts tableaux et figures, exécutés en aval, afin d'éviter toute duplication de code.

Les tableaux et figures numérotés sont précédés de leur script respectif (replié par défaut). Si plusieurs éléments sont produits par un même script, celui-ci est placé soit uniquement devant le premier élément, soit placé à plusieurs reprises avec une numérotation.

L'ensemble du matériel est accessible depuis un dépôt git en cliquant sur </> Code en haut à droite de la page.

Aucun large language model n'est utilisé pour la rédaction du code ou du texte.

! Le contenu de ce devoir n'est pas corrigé

```r
source("renv/activate.R")

# renv::install("~/Documents/pro/r_pkg/pkg_hebstr/")

library(tidyverse) |> suppressPackageStartupMessages()
library(tidymodels) |> suppressPackageStartupMessages()
library(rlang, warn.conflicts = F)
library(mice, warn.conflicts = F)
library(glue)
library(labelled)
library(gtsummary)
library(MatchIt)
library(halfmoon)
library(survival)
library(ggsurvfit)
library(patchwork)
library(hebstr)

update_geom_defaults("text", list(family = "Luciole"))

lang_fr()
```

```r
### LABELS ---------------------------------------------------------------------

.labels <- list(
  base = easy_recode(
    sex = c("sex" = "Sexe"),
    weight = c("wtkilo1" = "Poids, kg"),
    cancer = c("ca" = "Cancer"),
    ethnic = c("race" = "Origine ethnique"),
    educ = c("edu" = "Niveau d'études, grade"),
    income = c("income" = "Revenu, k$"),
    insur = c("ninsclas" = "Assurance maladie"),
    transfer = c("transhx" = "Transfert interhospitalier >24h"),
    proba_surv = c("surv2md1" = "Probabilité de survie à 60 jours, %"),
    dnr = c("dnr1" = "Limitation/arrêt des thérapeutiques actives"),
    rhc = c("swang1" = "Cathétérisme droit"),
    score_dasi = c("das2d3pc" = "DASI"),
```

```r
    score_apa = c("aps1" = "Score APACHE III"),
    score_gcs = c("scoma1" = "Score de Glasgow"),
    pv_temp = c("temp1" = "Température, °C"),
    pv_pam = c("meanbp1" = "Pression artérielle moyenne, mmHg"),
    pv_fc = c("hrt1" = "Fréquence cardiaque, bpm"),
    pv_fr = c("resp1" = "Fréquence respiratoire, rpm"),
    pv_paco2 = c("paco21" = "PaCO2, mmHg"),
    pv_pafi = c("pafi1" = "PaO2/FiO2, mmHg"),
    pv_ph = c("ph1" = "pH"),
    bio_leuco = c("wblc1" = "Leucocytémie, G/L"),
    bio_bili = c("bili1" = "Bilirubinémie, µM"),
    bio_creat = c("crea1" = "Créatininémie, µM"),
    bio_sodium = c("sod1" = "Natrémie, mM"),
    bio_kalium = c("pot1" = "Kaliémie, mM"),
    bio_hema = c("hema1" = "Hématocrite, %")
  ),
  new = list(
    org_fail = "Défaillance d'organe",
    tt_discharge = "Durée d'hospitalisation, jours",
    tt_death = "Durée jusqu'au décès, jours",
    ev_death_30 = "Mortalité à 30 jours",
    ev_death_180 = "Mortalité à 180 jours",
    age_cat = "Âge, années",
    n_diag = "Nb. de diagnostics à l'admission",
    n_comorb = "Nb. de comorbidités"
  )
)

.diag <- c(
  "resp", "card", "neuro", "gastr", "renal",
  "meta", "hema", "seps", "trauma", "ortho"
)

### DF ---------------------------------------------------------------------------

df_base <-
read_csv2("data/dm3.csv")[-1] |>
  set_names(tolower) |>
  mutate(across(ends_with("dte"), dmy)) |>
  relocate(!!!.labels$base$name)

df_setup <-
df_base |>
  mutate(across(c(cat1, cat2),
                ~ if_else(str_detect(., "Cancer"), NA, .)),
         across(all_of(.diag),
                ~ if_else(. == "Yes", "1", "0") |>
                  as.numeric()),
         across(ends_with(c("weight", "pam", "fc", "fr")),
                ~ na_if(., 0)),
         rhc = if_else(rhc == "RHC", 1, 0),
         ethnic = str_to_title(ethnic),
         educ = round(educ),
         dnr = if_else(dnr == "Yes", 1, 0),
         score_gcs = 15 - score_gcs * 0.12,
         bio_bili = bio_bili * 17.1,
         bio_creat = bio_creat * 88.4,
         org_fail =
           case_when(if_all(c(cat1, cat2), is.na) ~ "Aucune",
                     !str_detect(cat1, "MOSF") & !is.na(cat1) & is.na(cat2) |
                     !str_detect(cat2, "MOSF") & !is.na(cat2) & is.na(cat1) ~ "Uni",
                     .default = "Multi") |>
           fct_relevel("Aucune", "Uni", "Multi"),
         tt_discharge = as.numeric(dschdte - sadmdte),
```

```r
         tt_death = as.numeric(dthdte - sadmdte),
         ev_death_30 = case_when(tt_death <= 30 ~ 1, .default = 0),
         ev_death_180 = case_when(tt_death <= 180 ~ 1, .default = 0)) |>
  easy_fct(sex,
           "Homme" = "Male",
           "Femme" = "Female") |>
  easy_fct(ethnic,
           "Blanche" = "White",
           "Noire" = "Black",
           "Autre" = "Other") |>
  easy_fct(cancer,
           "Non" = "No",
           "Localisé" = "Yes",
           "Métastatique" = "Metastatic") |>
  easy_fct(income,
           "<11" = "Under $11k",
           "[11-25)" = "$11-$25k",
           "[25-50)" = "$25-$50k",
           ">=50" = "> $50k") |>
  easy_fct(insur,
           "PV" = "Private",
           "MR" = "Medicare",
           "PVMR" = "Private & Medicare",
           "MD" = "Medicaid",
           "MRMD" = "Medicare & Medicaid",
           "Aucune" = "No insurance") |>
  easy_fct(age,
           45, 75, .btw = 60,
           .name = "age_cat") |>
  easy_fct(educ, 9, 13) |>
  easy_fct(educ,
           "Élémentaire" = "<9",
           "Secondaire" = "[9-13)",
           "Supérieur" = ">=13") |>
  easy_fct(pv_temp, 35.5, 38.5) |>
  easy_fct(pv_ph, 7.38, 7.42) |>
  easy_fct(pv_pam, cut = 65) |>
  easy_fct(pv_paco2, 35, 45) |>
  easy_fct(pv_pafi, 100, 300, .btw = 200) |>
  easy_fct(pv_fr, 12, 20) |>
  easy_fct(pv_fc, 60, 100) |>
  easy_fct(bio_leuco, 7.5, 15) |>
  easy_fct(bio_sodium, 135, 145) |>
  easy_fct(bio_kalium, 3.5, 5) |>
  easy_fct(bio_hema, 40, 50) |>
  rowwise() |>
    mutate(n_diag = sum(across(all_of(.diag))),
           n_comorb = sum(across(ends_with("hx")))) |>
    ungroup() |>
  mutate(across(c(n_diag, n_comorb), as_factor)) |>
  set_variable_labels(!!!with(.labels, c(base$label, new))) |>
  select(where(~ !is.null(label_attribute(.))), -age)

load("data/df_imp.RData")

### OPTS ----------------------------------------------------------------------

set_opts(
  data = easy_descr(df_setup),
  view = easy_view(df_setup),
  parametric = c("weight", "score_apa"),
  acro = acro(
    PV ~ "privée",
    MR ~ "Medicare",
```

```r
    PVMR ~ "privée + Medicare",
    MD ~ "Medicaid",
    MRMD ~ "Medicare + Medicaid"
  ),
  line = list(
    lty = 2,
    color = set_opts()$color$warm[2],
    alpha = 0.5
  )
)

.miss_data <-
opts$view$data |>
  filter(!is.na(n_miss), variable != "tt_death") |>
  select(variable, label, n_miss, p_miss)

### BV VARS ---------------------------------------------------------------

.bv <-
  list(
    group = list(
      demo = c("sex", "age_cat", "ethnic", "educ", "income", "insur"),
      atcd = c("n_diag", "n_comorb", "cancer", "org_fail"),
      pv = str_subset(opts$data$ql$vars, "pv_"),
      bio = str_subset(opts$data$ql$vars, "bio_")
    ),
    vars = c("ev_death_30", "rhc")
  )

### SP ---------------------------------------------------------------------

sp_vars <-
df_setup |>
  select(-rhc, -starts_with(c("tt", "ev"))) |>
  names()

.sp_model <- logistic_reg() |> set_engine("glm")

.sp_recipe <-
recipe(formula = reformulate(sp_vars, "rhc"), data = df_imp) |>
  step_mutate(rhc = factor(rhc))

df_sp <-
workflow() |>
  add_model(.sp_model) |>
  add_recipe(.sp_recipe) |>
  fit(df_imp) |>
  augment(type.predict = "response", new_data = df_imp) |>
  rename(sp = .pred_1) |>
  mutate(rhc = factor(rhc)) |>
  set_variable_labels(sp = "Score de propension")

df_match_model <- matchit(
  formula = reformulate(sp_vars, "rhc"),
  data = df_sp,
  distance = "logit",
  caliper = 0.002,
  std.caliper = FALSE
)

df_match <- match.data(df_match_model)

compar_df <- list(
  non_ajusté = df_imp,
```

```
  ajusté = df_match
)

### AUTO EXEC ------------------------------------------------------------------

# auto_exec()
```

1 Data management

1.1 Composition initiale

Le jeu de données était constitué de **5735 observations** pour **62 variables** (sans prise en compte du numéro de ligne). Il se présentait au format long, soit une ligne par sujet. Il n'y avait pas de doublons.

1.1.a Valeurs aberrantes

Les variables suivantes contenaient des valeurs numériques **égales à 0 et jugées aberrantes** :

variable	label	n_ab	p_ab
weight	Poids, kg	515	9,0%
pv_pam	Pression artérielle moyenne, mmHg	80	1,4%
pv_fc	Fréquence cardiaque, bpm	159	2,8%
pv_fr	Fréquence respiratoire, rpm	136	2,4%

1.1.b Valeurs manquantes

Les variables suivantes contenaient initialement des valeurs **manquantes** :

variable	label	n_miss	p_miss
cat2	cat. diag. secondaire	4535	79,1%
dschdte	date de sortie	1	0,0%
dthdte	date de décès	2013	35,1%
adld3p	échelle ADL	4296	74,9%
urin1	diurèse	3028	52,8%

Il paraissait normal que l'ensemble des sujets puissent ne pas tous être porteurs d'un diagnostic secondaire.

La date de sortie manquante était considérée ***completely at random***.

Le nombre d'occurrence de la variable binaire `death`, correspondant au statut « décédé oui/non », était égale au nombre de sujets ayant une date de décès.

```r
identical(sum(df_base$death == "Yes"),
          sum(!is.na(df_base$dthdte)))
#> [1] TRUE
```

Ainsi il était possible d'affirmer que les dates de décès manquantes correspondaient à la **non-survenue du décès**.

La raison pour laquelle ADL et diurèse contenaient une telle proportion de valeurs manquantes n'était pas évidente. Celles-ci étaient considérées ***completely at random***.

! Remarque sur la variable `death`

Selon la documentation fournie, la variable binaire `death` était renseignée comme étant la **mortalité à 180 jours**. Or le nombre d'occurrences positives de cette variable était égal au nombre total de sujets décédés.

```r
count(df_base, death)
#> # A tibble: 2 × 2
#>   death     n
#>   <chr> <int>
#> 1 No     2013
#> 2 Yes    3722
```

Le calcul *de novo* d'une variable « **mortalité à 180 jours** » rapportait des effectifs différents.

```r
df_base |>
  count(death_180 =
          case_when(as.numeric(dthdte - sadmdte) <= 180 ~ "Yes",
                    .default = "No"))
#> # A tibble: 2 × 2
#>   death_180     n
#>   <chr>     <int>
#> 1 No         2906
#> 2 Yes        2829
```

Par conséquent la variable `death` correspondait bien, comme son nom l'indique, à la **mortalité toutes périodes confondues**, et non à la mortalité à 180 jours comme l'indiquait son libellé.

1.2 Recodage des variables

Hormis un formatage de base de la plupart des variables (i.e. renommage, factorisation, formatage des dates), certaines modifications spécifiques ont été réalisées.

1.2.a Synthèse des catégories diagnostiques

Les modalités des variables catégorielles `cat1` et `cat2` étaient les suivantes :

cat. diag. principale	n
ARF	2490
MOSF w/Sepsis	1227
COPD	457
CHF	456
Coma	436
MOSF w/Malignancy	399
Cirrhosis	224
Lung Cancer	39
Colon Cancer	7

cat. diag. secondaire	n
NA	4535
MOSF w/Sepsis	826
MOSF w/Malignancy	229
Coma	90
Cirrhosis	38
Lung Cancer	15
Colon Cancer	2

Ces variables étaient considérées problématiques du fait d'un mélange de complications aiguës et de pathologies chroniques.

Chez les sujets ayant au moins une occurrence « **cancer** » en `cat1` ou `cat2`, la variable `cancer` était systématiquement codée « **métastatique** ».

```
df_base |>
  filter(if_any(c(cat1, cat2), str_detect, "Cancer")) |>
  count(cancer)
#> # A tibble: 1 × 2
#>   cancer         n
#>   <chr>      <int>
#> 1 Metastatic    63
```

L'information relative au cancer étant déjà présente dans la variable `cancer`, la décision a été prise de **supprimer** les occurrences « cancer » de `cat1` et `cat2` par une conversion en **valeurs manquantes**.

Quant à des modalités telles que cirrhose ou BPCO, il n'y avait aucune indication concernant leur caractère aigu ou chronique. À défaut nous avons considéré qui s'agissait bien de **décompensations aiguës** et que leur présence au sein de ces variables était donc justifiée.

Aucune distinction n'était faite entre les deux catégories de défaillance multiviscérale « MOSF ».

Finalement, l'information apportée par `cat1` et `cat2` a été regroupée en une nouvelle variable catégorielle substitutive nommée « **défaillance d'organe** » (`org_fail`) :

modalité	condition
aucune	aucun diagnostic parmi `cat1` et `cat2`
uni	un seul diagnostic parmi `cat1` et `cat2` hormis MOSF
multi	deux diagnostics ou au moins une MOSF parmi `cat1` et `cat2`

1.2.b Synthèse des diagnostics et comorbidités

L'information relative aux diagnostics à l'admission a été synthétisée en une nouvelle variable numérique « **nombre de diagnostics à l'admission** » (`n_diag`), comptabilisant la somme des diagnostics à l'admission pour chaque sujet.

L'information relative aux comorbidités (variables `*hx` hormis `transhx`) a été synthétisée en une nouvelle variable numérique « **nombre de comorbidités** » (`n_comorb`), comptabilisant la somme des comorbidités pour chaque sujet.
Seule la variable `transhx` correspondant au « **transfert interhospitalier >24h** » a été extraite de cette catégorie et conservée telle quelle.

1.2.c Factorisation du niveau d'études

La variable numérique « **niveau d'études** » représentait le nombre d'années de scolarisation dans le système étasunien. Elle a été factorisée en 3 catégories :

modalité	description
élémentaire	<= 8 années (équivalent collège dans le système français)
secondaire	9 à 12 années (équivalent lycée dans le système français)
supérieur	> 12 années

1.2.d Conversion des unités de mesures

Les variables suivantes ont été converties en unités du Système International :

- Bilirubinémie : exprimée en mg/dL, convertie en µM (x 17,1)
- Créatininémie : exprimée en mg/dL, convertie en µM (x 88,4)

> **Note**
>
> Les variables « bilirubinémie » (`bio_bili`) et « créatininémie » (`bio_creat`) sont les seules variables biologiques n'ayant pas été catégorisées du fait qu'elles s'interprètent davantage de manière continue que graduelle.

Le score de Glasgow, coté de 0 (vigilance normale) à 100 (coma), a été replacé sur une **échelle de 3 à 15** par transformation linéaire (15 - valeur x 0,12).

1.2.e Calcul des délais et outcomes

Les variables suivantes ont été créées sur la base des dates d'admission, de sortie d'hospitalisation et de décès.

variable	label	type	n_miss	p_miss
tt_discharge	Durée d'hospitalisation, jours	num	1	0,0%
tt_death	Durée jusqu'au décès, jours	num	2013	35,1%

Aucune erreur logique ne fut retrouvée.

```
df_base |>
  filter(dschdte < sadmdte | dthdte < dschdte) |>
  nrow()
#> [1] 0
```

1.2.f Classes d'âges

Une variable catégorielle *« classes d'âges »* (`age_cat`) a été créée sur la base de la variable continue `age`.

variable	label	type	levels
age_cat	Âge, années	fct	<45, [45-60), [60-75), >=75

1.2.g Exclusions

Certaines variables ont été exclues du jeu de données pour trois raisons.

1. **Excès de valeurs manquantes** :

variable	label	type	n_miss	p_miss	range	q1_q2_q3
adld3p	échelle ADL	num	4296	74,9%	0, 7	0, 0, 2
urin1	diurèse	num	3028	52,8%	0, 9000	1110, 1927, 2955

2. **Interprétabilité trop incertaine** :

variable	label	type	n_miss	p_miss	range	q1_q2_q3
lstctdte	date de dernier contact	date			1989-06-13, 1994-08-14	
alb1	albuminé-mie	num			0,3, 29,0	2,6, 3,5, 3,5

3. **Pas ou plus d'utilité future** :

variable	label	type	n_miss	p_miss	range
ptid	identifiant patient	chr			
cat1	cat. diag. principale	chr			
cat2	cat. diag. se-condaire	chr	4535	79,1%	
sadmdte	date d'admission	date			1989-06-11, 1994-01-23
dschdte	date de sor-tie	date	1	0,0%	1989-06-14, 1994-05-22
dthdte	date de dé-cès	date	2013	35,1%	1989-06-14, 1994-12-31
death	décès	chr			

1.2.h Gestion des valeurs aberrantes

Les valeurs jugées aberrantes ont été converties en **valeurs manquantes**.

La proportion de valeurs manquantes pour chacune des variables suivantes était jugée raisonnable :

variable	label	n_miss	p_miss
weight	Poids, kg	515	9,0%
pv_pam	Pression artérielle moyenne, mmHg	80	1,4%
pv_fc	Fréquence cardiaque, bpm	159	2,8%
pv_fr	Fréquence respiratoire, rpm	136	2,4%
tt_discharge	Durée d'hospitalisation, jours	1	0,0%

1.3 Composition finale

Ci-dessous le récapitulatif des variables analysées :

Search

n	variable	label	type
1	sex	Sexe	fct
2	weight	Poids, kg	num
3	cancer	Cancer	fct
4	ethnic	Origine ethnique	fct
5	educ	Niveau d'études, grade	fct
6	income	Revenu, k$	fct
7	insur	Assurance maladie	fct
8	transfer	Transfert interhospitalier >24h	bin
9	proba_surv	Probabilité de survie à 60 jours, %	num
10	dnr	Limitation/arrêt des thérapeutiques actives	bin
11	rhc	Cathétérisme droit	bin
12	score_dasi	DASI	num
13	score_apa	Score APACHE III	num
14	score_gcs	Score de Glasgow	num
15	pv_temp	Température, °C	fct
16	pv_pam	Pression artérielle moyenne, mmHg	fct
17	pv_fc	Fréquence cardiaque, bpm	fct
18	pv_fr	Fréquence respiratoire, rpm	fct
19	pv_paco2	PaCO2, mmHg	fct
20	pv_pafi	PaO2/FiO2, mmHg	fct
21	pv_ph	pH	fct
22	bio_leuco	Leucocytémie, G/L	fct
23	bio_bili	Bilirubinémie, µM	num
24	bio_creat	Créatininémie, µM	num
25	bio_sodium	Natrémie, mM	fct
26	bio_kalium	Kaliémie, mM	fct
27	bio_hema	Hématocrite, %	fct
28	org_fail	Défaillance d'organe	fct
29	tt_discharge	Durée d'hospitalisation, jours	num
30	tt_death	Durée jusqu'au décès, jours	num
31	ev_death_30	Mortalité à 30 jours	bin
32	ev_death_180	Mortalité à 180 jours	bin
33	age_cat	Âge, années	fct
34	n_diag	Nb. de diagnostics à l'admission	fct
35	n_comorb	Nb. de comorbidités	fct

2 Analyse descriptive univariée

Les variables catégorielles ont pu être regroupées en 4 catégories :

- Variables sociodémographiques
- Antécédents et comorbidités
- Paramètres vitaux (`pv_*`)
- Paramètres biologiques (`bio_*`)

```
fig_uv <- \(type) {

  .size <-
  list(demo = c(10, 7.5),
       atcd = c(7.5, 8.5),
       pv = c(12.5, 7),
       bio = c(6.5, 7))

  fig <-
  .bv$group[[type]] |>
    map(~ df_setup |>
          ggcount(var = .,
                  size = 3,
                  color = opts$palette[2]) +
          scale_y_continuous(n.breaks = 6)) |>
    wrap_plots(ncol = 2) +
    plot_layout(axis_titles = "collect_y")

  easy_out(fig,
           filename = glue("fig_uv_{type}"),
           size = .size[[type]])

}

map(names(.bv$group), fig_uv)
```

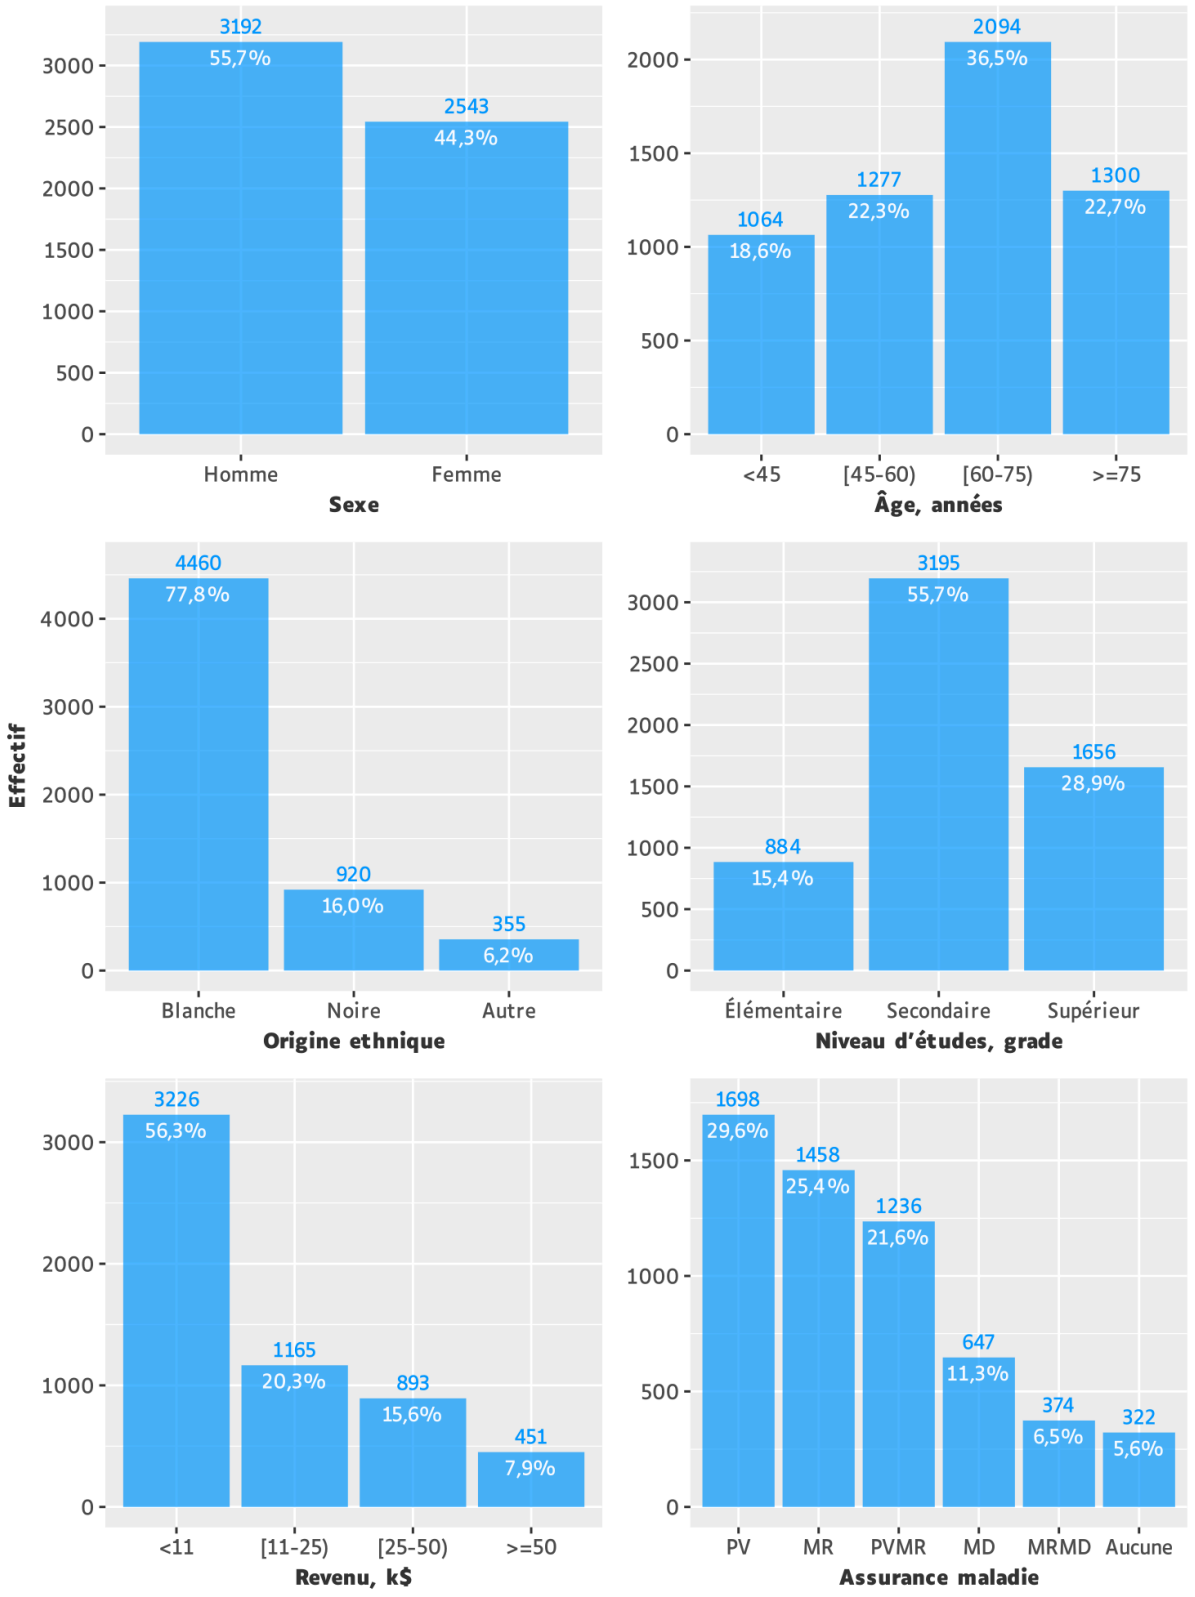

Figure 1. – Caractéristiques des variables sociodémographiques. PV : privée ; MR : Medicare ; PVMR : privée + Medicare ; MD : Medicaid ; MRMD : Medicare + Medicaid.

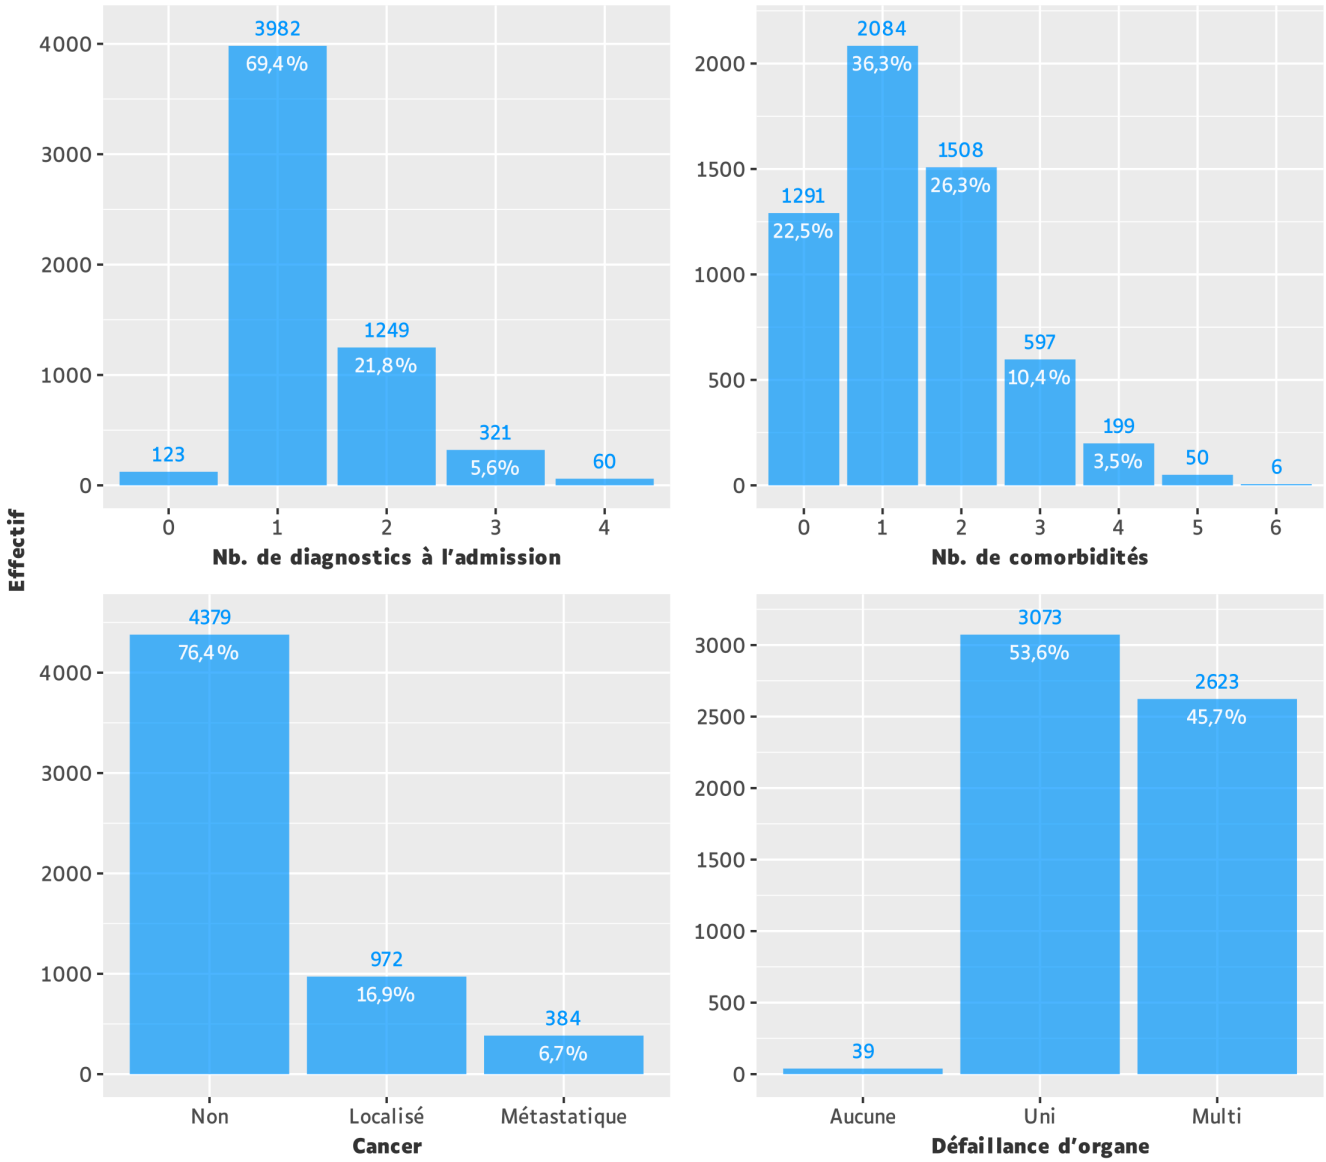

Figure 2. – Caractéristiques des antécédents et comorbidités.

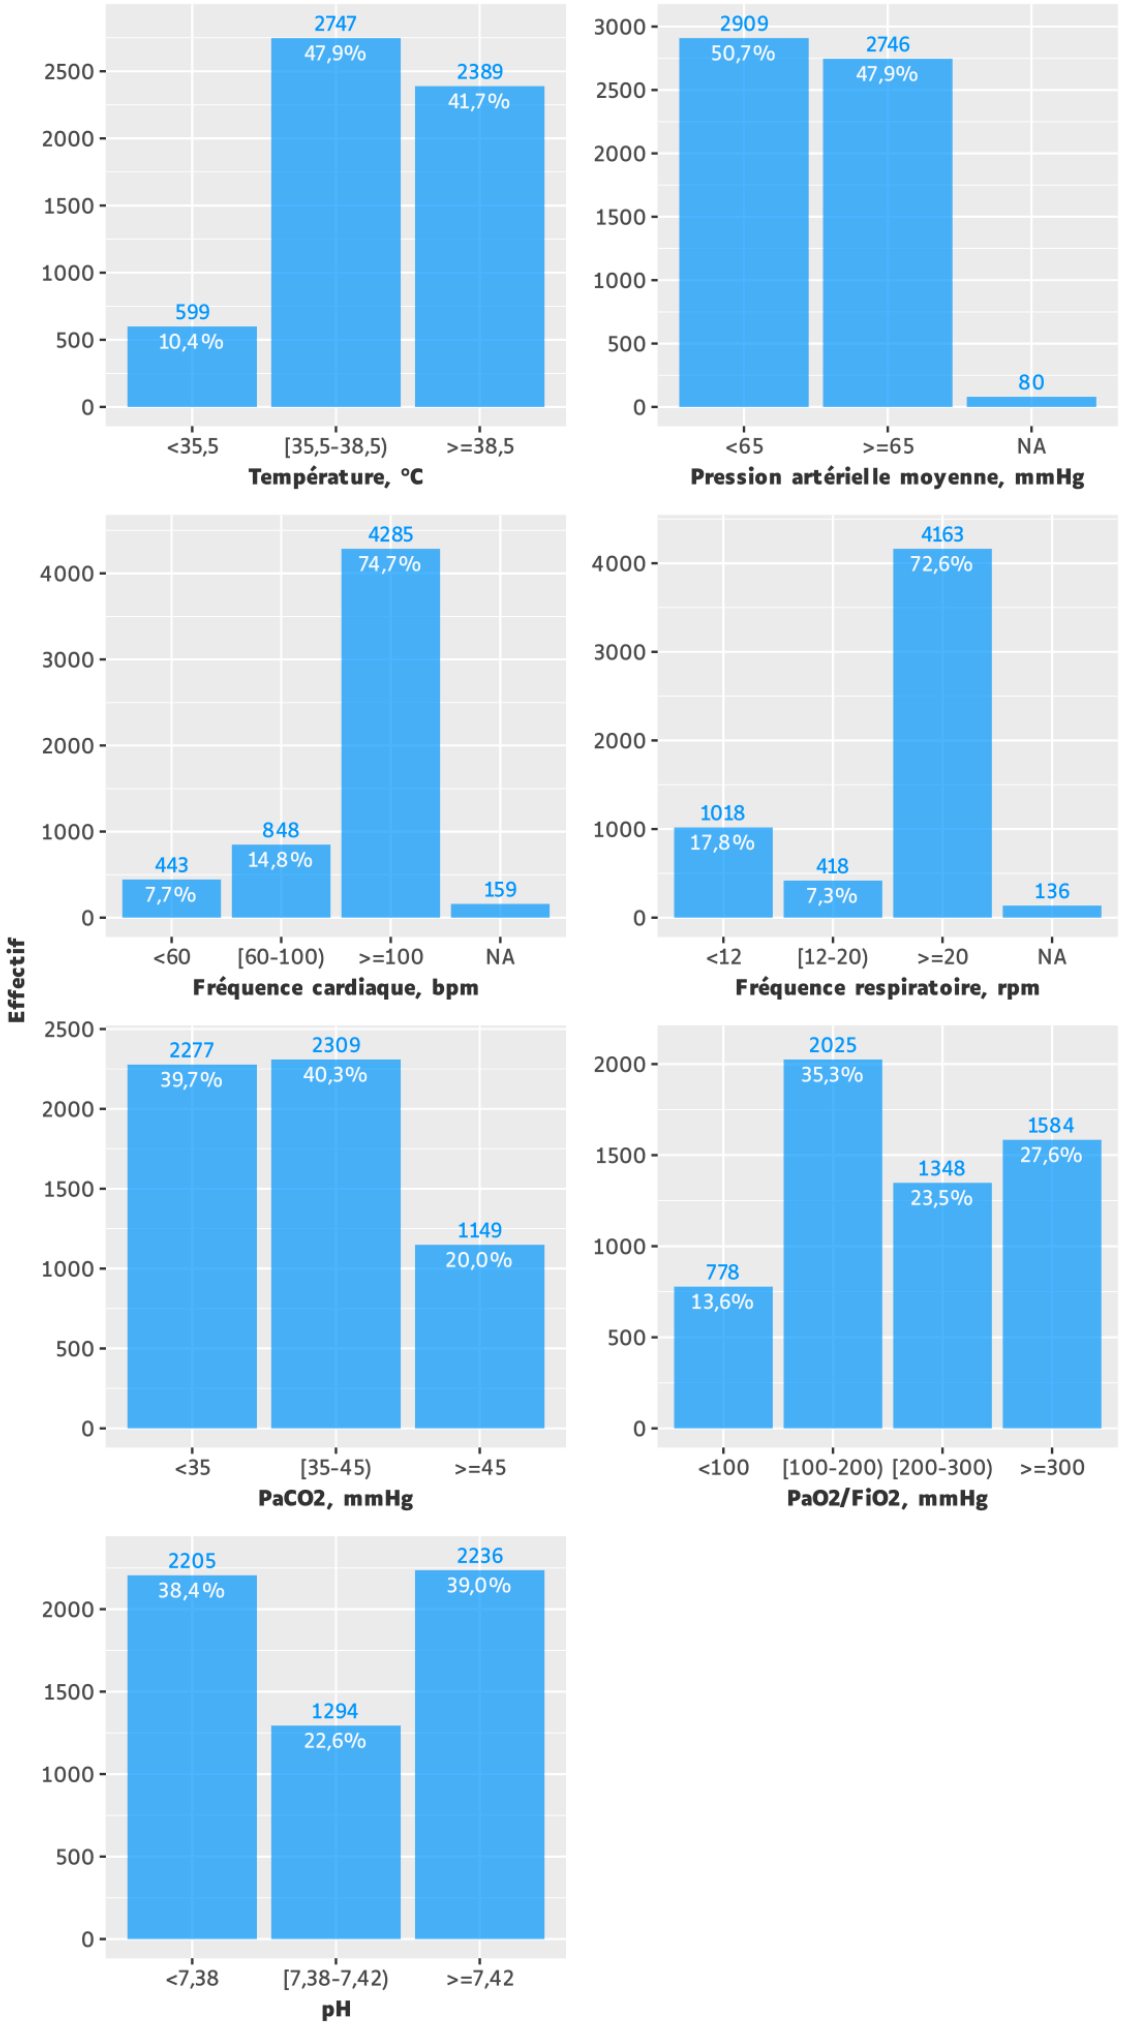

Figure 3. – Caractéristiques des paramètres vitaux.

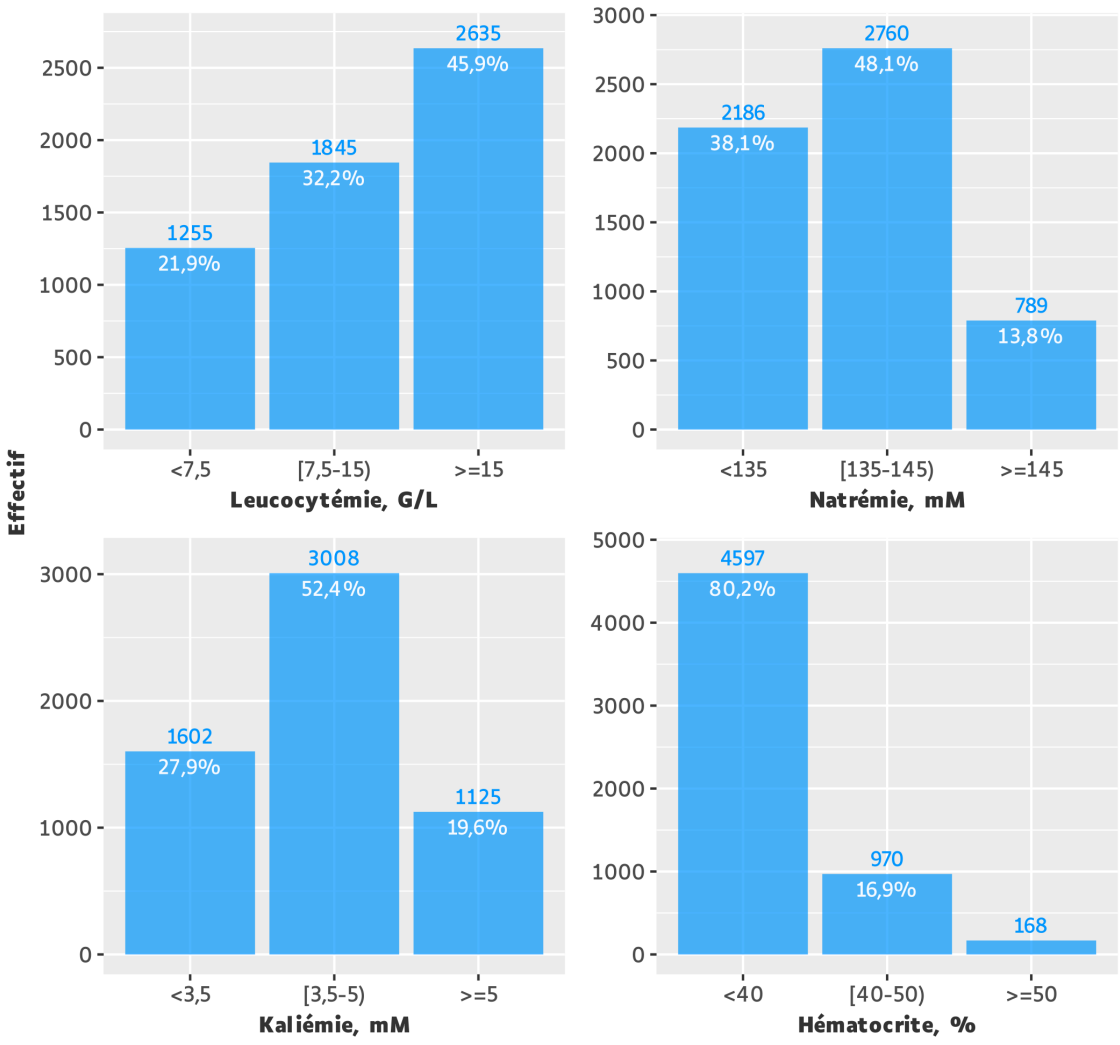

Figure 4. – Caractéristiques des paramètres biologiques.

```
### QT ---------------------------------------------------------------------

df_setup |>
  tbl_wide_summary(
    include = opts$data$qt$vars$total,
    statistic = opts$qt_stat_wide,
    digits = list(~ 1, proba_surv ~ 2)
  ) |>
  modify_header(
    label ~ glue("**{opts$labs$header}**"),
    stat_6 ~ glue("**{names(opts$qt_stat$mean)}**")
  ) |>
  gt_format(width = 650) |>
  easy_out("tbl_uv_qt")

### BIN ---------------------------------------------------------------------

df_setup |>
  tbl_summary(
    include = opts$data$bin$vars,
    statistic = opts$vars$stat[[3]],
    digits = opts$digits,
    missing = "no"
  ) |>
```

```
gtsum_format(label_stat = names(opts$ql_stat$n)) |>
gt_format(width = 400) |>
easy_out("tbl_uv_bin")
```

Tableau 1. – Caractéristiques des variables binaires.

Variable	n (%)
Transfert interhospitalier >24h	662 (11,5)
Limitation/arrêt des thérapeutiques actives	654 (11,4)
Cathétérisme droit	2 184 (38,1)
Mortalité à 30 jours	1 918 (33,4)
Mortalité à 180 jours	2 829 (49,3)

Tableau 2. – Caractéristiques des variables continues.

Variable	Min	Q1	Médiane	Q3	Max	Moyenne±SD
Poids, kg	19,5	60,4	72,2	85,2	244,0	74,5±20,7
Probabilité de survie à 60 jours, %	0,00	0,47	0,63	0,74	0,96	0,59±0,20
DASI	11,0	16,1	19,7	23,4	33,0	20,5±5,3
Score APACHE III	3,0	41,0	54,0	67,0	147,0	54,7±20,0
Score de Glasgow	3,0	10,1	15,0	15,0	15,0	12,5±3,6
Bilirubinémie, µM	1,7	13,7	17,3	23,9	995,1	38,8±82,1
Créatininémie, µM	8,8	88,4	132,6	212,2	2 218,6	188,6±181,5
Durée d'hospitalisation, jours	2,0	7,0	14,0	25,0	342,0	21,5±25,4
Durée jusqu'au décès, jours	2,0	8,0	28,0	166,0	1 943,0	162,2±295,6
Q1 : 1er quartile ; Q3 : 3e quartile ; SD : écart-type.						

! Parti pris

Seules les distributions du **poids** (`weight`) et du **score APACHE III** (`score_apa`) ont été considérées approximativement normales.

3 Analyse descriptive bivariée

L'analyse précédente a été reproduite après croisement sur 2 variables :

- Mortalité à 30 jours (`ev_death_30`)
- Cathétérisme droit (`rhc`)

3.1 Mortalité à 30 jours

::: {add-from=/home/julien/Documents/pro/m2/m2_dm3/scripts/tbl_bv_ql.R code-line-numbers=‹ true › code-file-name=tbl_bv_ql.R (1)}

```

```

:::

Tableau 3. – Caractéristiques des variables sociodémographiques selon la mortalité à 30 jours.

Variable	Total(N=5735)	Mortalité à 30 jours	
		0(n=3817, 66,6%)	1(n=1918, 33,4%)
Cathétérisme droit, n (%)	2 184 (38,1)	1 354 (35,5)	830 (43,3)
Sexe, n (%)			
Homme	3 192 (55,7)	2 116 (55,4)	1 076 (56,1)
Femme	2 543 (44,3)	1 701 (44,6)	842 (43,9)
Âge, années, n (%)			
<45	1 064 (18,6)	779 (20,4)	285 (14,9)
[45-60)	1 277 (22,3)	878 (23,0)	399 (20,8)
[60-75)	2 094 (36,5)	1 382 (36,2)	712 (37,1)
>=75	1 300 (22,7)	778 (20,4)	522 (27,2)
Origine ethnique, n (%)			
Blanche	4 460 (77,8)	2 971 (77,8)	1 489 (77,6)
Noire	920 (16,0)	615 (16,1)	305 (15,9)
Autre	355 (6,2)	231 (6,1)	124 (6,5)
Niveau d'études, grade, n (%)			
Élémentaire	884 (15,4)	589 (15,4)	295 (15,4)
Secondaire	3 195 (55,7)	2 129 (55,8)	1 066 (55,6)
Supérieur	1 656 (28,9)	1 099 (28,8)	557 (29,0)
Revenu, k$, n (%)			
<11	3 226 (56,3)	2 073 (54,3)	1 153 (60,1)
[11-25)	1 165 (20,3)	794 (20,8)	371 (19,3)
[25-50)	893 (15,6)	634 (16,6)	259 (13,5)
>=50	451 (7,9)	316 (8,3)	135 (7,0)
Assurance maladie, n (%)			
PV	1 698 (29,6)	1 173 (30,7)	525 (27,4)
MR	1 458 (25,4)	930 (24,4)	528 (27,5)
PVMR	1 236 (21,6)	782 (20,5)	454 (23,7)
MD	647 (11,3)	473 (12,4)	174 (9,1)
MRMD	374 (6,5)	251 (6,6)	123 (6,4)
Aucune	322 (5,6)	208 (5,4)	114 (5,9)

PV : privée ; MR : Medicare ; PVMR : privée + Medicare ; MD : Medicaid ; MRMD : Medicare + Medicaid.

Tableau 4. – Caractéristiques des antécédents et comorbidités selon la mortalité à 30 jours.

Variable	Total(N=5735)	Mortalité à 30 jours	
		0(n=3817, 66,6%)	1(n=1918, 33,4%)
Cathétérisme droit, n (%)	2 184 (38,1)	1 354 (35,5)	830 (43,3)
Nb. de diagnostics à l'admission, n (%)			
0	123 (2,1)	85 (2,2)	38 (2,0)
1	3 982 (69,4)	2 723 (71,3)	1 259 (65,6)
2	1 249 (21,8)	795 (20,8)	454 (23,7)
3	321 (5,6)	184 (4,8)	137 (7,1)
4	60 (1,0)	30 (0,8)	30 (1,6)
Nb. de comorbidités, n (%)			
0	1 291 (22,5)	905 (23,7)	386 (20,1)
1	2 084 (36,3)	1 345 (35,2)	739 (38,5)
2	1 508 (26,3)	966 (25,3)	542 (28,3)
3	597 (10,4)	424 (11,1)	173 (9,0)
4	199 (3,5)	139 (3,6)	60 (3,1)
5	50 (0,9)	35 (0,9)	15 (0,8)
6	6 (0,1)	3 (0,1)	3 (0,2)
Cancer, n (%)			
Non	4 379 (76,4)	3 050 (79,9)	1 329 (69,3)
Localisé	972 (16,9)	559 (14,6)	413 (21,5)
Métastatique	384 (6,7)	208 (5,4)	176 (9,2)
Défaillance d'organe, n (%)			
Aucune	39 (0,7)	28 (0,7)	11 (0,6)
Uni	3 073 (53,6)	2 247 (58,9)	826 (43,1)
Multi	2 623 (45,7)	1 542 (40,4)	1 081 (56,4)

Tableau 5. – Caractéristiques des paramètres vitaux selon la mortalité à 30 jours.

Variable	Total(N=5735)	Mortalité à 30 jours	
		0(n=3817, 66,6%)	1(n=1918, 33,4%)
Cathétérisme droit, n (%)	2 184 (38,1)	1 354 (35,5)	830 (43,3)
Température, °C, n (%)			
<35,5	599 (10,4)	335 (8,8)	264 (13,8)
[35,5-38,5)	2 747 (47,9)	1 900 (49,8)	847 (44,2)
>=38,5	2 389 (41,7)	1 582 (41,4)	807 (42,1)
Pression artérielle moyenne, mmHg, n (%)			
<65	2 909 (51,4)	1 820 (48,1)	1 089 (58,1)
>=65	2 746 (48,6)	1 960 (51,9)	786 (41,9)
Fréquence cardiaque, bpm, n (%)			
<60	443 (7,9)	316 (8,4)	127 (7,0)
[60-100)	848 (15,2)	601 (16,0)	247 (13,5)
>=100	4 285 (76,8)	2 834 (75,6)	1 451 (79,5)
Fréquence respiratoire, rpm, n (%)			
<12	1 018 (18,2)	648 (17,3)	370 (20,0)
[12-20)	418 (7,5)	274 (7,3)	144 (7,8)
>=20	4 163 (74,4)	2 831 (75,4)	1 332 (72,2)
PaCO2, mmHg, n (%)			
<35	2 277 (39,7)	1 409 (36,9)	868 (45,3)
[35-45)	2 309 (40,3)	1 602 (42,0)	707 (36,9)
>=45	1 149 (20,0)	806 (21,1)	343 (17,9)
PaO2/FiO2, mmHg, n (%)			
<100	778 (13,6)	459 (12,0)	319 (16,6)
[100-200)	2 025 (35,3)	1 342 (35,2)	683 (35,6)
[200-300)	1 348 (23,5)	918 (24,1)	430 (22,4)
>=300	1 584 (27,6)	1 098 (28,8)	486 (25,3)
pH, n (%)			
<7,38	2 205 (38,4)	1 411 (37,0)	794 (41,4)
[7,38-7,42)	1 294 (22,6)	930 (24,4)	364 (19,0)
>=7,42	2 236 (39,0)	1 476 (38,7)	760 (39,6)

Tableau 6. – Caractéristiques des paramètres biologiques selon la mortalité à 30 jours.

Variable	Total(N=5735)	Mortalité à 30 jours	
		0(n=3817, 66,6%)	1(n=1918, 33,4%)
Cathétérisme droit, n (%)	2 184 (38,1)	1 354 (35,5)	830 (43,3)
Leucocytémie, G/L, n (%)			
<7,5	1 255 (21,9)	795 (20,8)	460 (24,0)
[7,5-15)	1 845 (32,2)	1 321 (34,6)	524 (27,3)
>=15	2 635 (45,9)	1 701 (44,6)	934 (48,7)
Natrémie, mM, n (%)			
<135	2 186 (38,1)	1 436 (37,6)	750 (39,1)
[135-145)	2 760 (48,1)	1 904 (49,9)	856 (44,6)
>=145	789 (13,8)	477 (12,5)	312 (16,3)
Kaliémie, mM, n (%)			
<3,5	1 602 (27,9)	1 035 (27,1)	567 (29,6)
[3,5-5)	3 008 (52,4)	2 078 (54,4)	930 (48,5)
>=5	1 125 (19,6)	704 (18,4)	421 (21,9)
Hématocrite, %, n (%)			
<40	4 597 (80,2)	2 985 (78,2)	1 612 (84,0)
[40-50)	970 (16,9)	705 (18,5)	265 (13,8)
>=50	168 (2,9)	127 (3,3)	41 (2,1)

::: {add-from=/home/julien/Documents/pro/m2/m2_dm3/scripts/tbl_bv_qt.R code-line-numbers=‹ true › code-file-name=tbl_bv_qt.R (1)}

:::

Tableau 7. – Caractéristiques des variables binaires selon la mortalité à 30 jours.

Variable	Total(N=5735)	Mortalité à 30 jours	
		0(n=3817, 66,6%)	1(n=1918, 33,4%)
Transfert interhospitalier >24h, n (%)	662 (11,5)	449 (11,8)	213 (11,1)
Limitation/arrêt des thérapeutiques actives, n (%)	654 (11,4)	257 (6,7)	397 (20,7)
Cathétérisme droit, n (%)	2 184 (38,1)	1 354 (35,5)	830 (43,3)
Mortalité à 180 jours, n (%)	2 829 (49,3)	911 (23,9)	1 918 (100,0)

Tableau 8. – Caractéristiques des variables continues selon la mortalité à 30 jours.

Variable	Total(N=5735)	Mortalité à 30 jours	
		0(n=3817, 66,6%)	1(n=1918, 33,4%)
Poids, kg, Médiane (Q1, Q3)	72,2 (60,4, 85,2)	72,7 (61,0, 85,5)	71,0 (59,6, 84,4)
Probabilité de survie à 60 jours, %, Médiane (Q1, Q3)	0,63 (0,47, 0,74)	0,68 (0,56, 0,77)	0,50 (0,35, 0,64)
DASI, Médiane (Q1, Q3)	19,7 (16,1, 23,4)	20,0 (16,1, 24,1)	19,6 (16,4, 22,2)
Score APACHE III, Médiane (Q1, Q3)	54,0 (41,0, 67,0)	50,0 (39,0, 63,0)	60,0 (47,0, 74,0)
Score de Glasgow, Médiane (Q1, Q3)	15,0 (10,1, 15,0)	15,0 (11,9, 15,0)	13,9 (9,7, 15,0)
Bilirubinémie, µM, Médiane (Q1, Q3)	17,3 (13,7, 23,9)	17,3 (13,7, 20,5)	17,3 (15,4, 32,5)
Créatininémie, µM, Médiane (Q1, Q3)	132,6 (88,4, 212,2)	123,8 (79,6, 194,5)	150,3 (97,2, 238,7)
Durée d'hospitalisation, jours, Médiane (Q1, Q3)	14,0 (7,0, 25,0)	17,0 (10,0, 35,0)	8,0 (4,0, 15,0)
Durée jusqu'au décès, jours, Médiane (Q1, Q3)	28,0 (8,0, 166,0)	176,0 (67,0, 440,0)	8,0 (5,0, 16,0)
Q1 : 1er quartile ; Q3 : 3e quartile.			

3.2 Cathétérisme droit

::: {add-from=/home/julien/Documents/pro/m2/m2_dm3/scripts/tbl_bv_ql.R code-line-numbers=‹ true › code-filename=tbl_bv_ql.R (2)}

:::

Tableau 9. – Caractéristiques des variables sociodémographiques selon la pose de cathétérisme droit.

Variable	Total(N=5735)	Cathétérisme droit	
		0(n=3551, 61,9%)	1(n=2184, 38,1%)
Mortalité à 30 jours, n (%)	1 918 (33,4)	1 088 (30,6)	830 (38,0)
Sexe, n (%)			
Homme	3 192 (55,7)	1 914 (53,9)	1 278 (58,5)
Femme	2 543 (44,3)	1 637 (46,1)	906 (41,5)
Âge, années, n (%)			
<45	1 064 (18,6)	680 (19,1)	384 (17,6)
[45-60)	1 277 (22,3)	750 (21,1)	527 (24,1)
[60-75)	2 094 (36,5)	1 234 (34,8)	860 (39,4)
>=75	1 300 (22,7)	887 (25,0)	413 (18,9)
Origine ethnique, n (%)			
Blanche	4 460 (77,8)	2 753 (77,5)	1 707 (78,2)
Noire	920 (16,0)	585 (16,5)	335 (15,3)
Autre	355 (6,2)	213 (6,0)	142 (6,5)
Niveau d'études, grade, n (%)			
Élémentaire	884 (15,4)	586 (16,5)	298 (13,6)
Secondaire	3 195 (55,7)	2 006 (56,5)	1 189 (54,4)
Supérieur	1 656 (28,9)	959 (27,0)	697 (31,9)
Revenu, k$, n (%)			
<11	3 226 (56,3)	2 081 (58,6)	1 145 (52,4)
[11-25)	1 165 (20,3)	713 (20,1)	452 (20,7)
[25-50)	893 (15,6)	500 (14,1)	393 (18,0)
>=50	451 (7,9)	257 (7,2)	194 (8,9)
Assurance maladie, n (%)			
PV	1 698 (29,6)	967 (27,2)	731 (33,5)
MR	1 458 (25,4)	947 (26,7)	511 (23,4)
PVMR	1 236 (21,6)	746 (21,0)	490 (22,4)
MD	647 (11,3)	454 (12,8)	193 (8,8)
MRMD	374 (6,5)	251 (7,1)	123 (5,6)
Aucune	322 (5,6)	186 (5,2)	136 (6,2)

PV : privée ; MR : Medicare ; PVMR : privée + Medicare ; MD : Medicaid ; MRMD : Medicare + Medicaid.

Tableau 10. – Caractéristiques des antécédents et comorbidités selon la pose de cathétérisme droit.

Variable	Total(N=5735)	Cathétérisme droit	
		0(n=3551, 61,9%)	1(n=2184, 38,1%)
Mortalité à 30 jours, n (%)	1 918 (33,4)	1 088 (30,6)	830 (38,0)
Nb. de diagnostics à l'admission, n (%)			
0	123 (2,1)	83 (2,3)	40 (1,8)
1	3 982 (69,4)	2 503 (70,5)	1 479 (67,7)
2	1 249 (21,8)	751 (21,1)	498 (22,8)
3	321 (5,6)	182 (5,1)	139 (6,4)
4	60 (1,0)	32 (0,9)	28 (1,3)
Nb. de comorbidités, n (%)			
0	1 291 (22,5)	768 (21,6)	523 (23,9)
1	2 084 (36,3)	1 296 (36,5)	788 (36,1)
2	1 508 (26,3)	924 (26,0)	584 (26,7)
3	597 (10,4)	378 (10,6)	219 (10,0)
4	199 (3,5)	143 (4,0)	56 (2,6)
5	50 (0,9)	37 (1,0)	13 (0,6)
6	6 (0,1)	5 (0,1)	1 (0,0)
Cancer, n (%)			
Non	4 379 (76,4)	2 652 (74,7)	1 727 (79,1)
Localisé	972 (16,9)	638 (18,0)	334 (15,3)
Métastatique	384 (6,7)	261 (7,4)	123 (5,6)
Défaillance d'organe, n (%)			
Aucune	39 (0,7)	33 (0,9)	6 (0,3)
Uni	3 073 (53,6)	2 171 (61,1)	902 (41,3)
Multi	2 623 (45,7)	1 347 (37,9)	1 276 (58,4)

Tableau 11. – Caractéristiques des paramètres vitaux selon la pose de cathétérisme droit.

Variable	Total(N=5735)	Cathétérisme droit	
		0(n=3551, 61,9%)	1(n=2184, 38,1%)
Mortalité à 30 jours, n (%)	1 918 (33,4)	1 088 (30,6)	830 (38,0)
Température, °C, n (%)			
<35,5	599 (10,4)	337 (9,5)	262 (12,0)
[35,5-38,5)	2 747 (47,9)	1 753 (49,4)	994 (45,5)
>=38,5	2 389 (41,7)	1 461 (41,1)	928 (42,5)
Pression artérielle moyenne, mmHg, n (%)			
<65	2 909 (51,4)	1 551 (44,1)	1 358 (63,5)
>=65	2 746 (48,6)	1 967 (55,9)	779 (36,5)
Fréquence cardiaque, bpm, n (%)			
<60	443 (7,9)	327 (9,4)	116 (5,5)
[60-100)	848 (15,2)	571 (16,5)	277 (13,1)
>=100	4 285 (76,8)	2 571 (74,1)	1 714 (81,3)
Fréquence respiratoire, rpm, n (%)			
<12	1 018 (18,2)	565 (16,3)	453 (21,3)
[12-20)	418 (7,5)	224 (6,5)	194 (9,1)
>=20	4 163 (74,4)	2 682 (77,3)	1 481 (69,6)
PaCO2, mmHg, n (%)			
<35	2 277 (39,7)	1 294 (36,4)	983 (45,0)
[35-45)	2 309 (40,3)	1 442 (40,6)	867 (39,7)
>=45	1 149 (20,0)	815 (23,0)	334 (15,3)
PaO2/FiO2, mmHg, n (%)			
<100	778 (13,6)	309 (8,7)	469 (21,5)
[100-200)	2 025 (35,3)	1 188 (33,5)	837 (38,3)
[200-300)	1 348 (23,5)	902 (25,4)	446 (20,4)
>=300	1 584 (27,6)	1 152 (32,4)	432 (19,8)
pH, n (%)			
<7,38	2 205 (38,4)	1 255 (35,3)	950 (43,5)
[7,38-7,42)	1 294 (22,6)	877 (24,7)	417 (19,1)
>=7,42	2 236 (39,0)	1 419 (40,0)	817 (37,4)

Tableau 12. – Caractéristiques des paramètres biologiques selon la pose de cathétérisme droit.

Variable	Total(N=5735)	Cathétérisme droit	
		0(n=3551, 61,9%)	1(n=2184, 38,1%)
Mortalité à 30 jours, n (%)	1 918 (33,4)	1 088 (30,6)	830 (38,0)
Leucocytémie, G/L, n (%)			
<7,5	1 255 (21,9)	779 (21,9)	476 (21,8)
[7,5-15)	1 845 (32,2)	1 201 (33,8)	644 (29,5)
>=15	2 635 (45,9)	1 571 (44,2)	1 064 (48,7)
Natrémie, mM, n (%)			
<135	2 186 (38,1)	1 283 (36,1)	903 (41,3)
[135-145)	2 760 (48,1)	1 774 (50,0)	986 (45,1)
>=145	789 (13,8)	494 (13,9)	295 (13,5)
Kaliémie, mM, n (%)			
<3,5	1 602 (27,9)	952 (26,8)	650 (29,8)
[3,5-5)	3 008 (52,4)	1 911 (53,8)	1 097 (50,2)
>=5	1 125 (19,6)	688 (19,4)	437 (20,0)
Hématocrite, %, n (%)			
<40	4 597 (80,2)	2 705 (76,2)	1 892 (86,6)
[40-50)	970 (16,9)	721 (20,3)	249 (11,4)
>=50	168 (2,9)	125 (3,5)	43 (2,0)

::: {add-from=/home/julien/Documents/pro/m2/m2_dm3/scripts/tbl_bv_qt.R code-line-numbers=‹ true › code-file-name=tbl_bv_qt.R (2)}

:::

Tableau 13. – Caractéristiques des variables binaires selon la pose de cathétérisme droit.

Variable	Total(N=5735)	Cathétérisme droit	
		0(n=3551, 61,9%)	1(n=2184, 38,1%)
Transfert interhospitalier >24h, n (%)	662 (11,5)	335 (9,4)	327 (15,0)
Limitation/arrêt des thérapeutiques actives, n (%)	654 (11,4)	499 (14,1)	155 (7,1)
Mortalité à 30 jours, n (%)	1 918 (33,4)	1 088 (30,6)	830 (38,0)
Mortalité à 180 jours, n (%)	2 829 (49,3)	1 650 (46,5)	1 179 (54,0)

Tableau 14. – Caractéristiques des variables continues selon la pose de cathétérisme droit.

Variable	Total(N=5735)	Cathétérisme droit	
		0(n=3551, 61,9%)	1(n=2184, 38,1%)
Poids, kg, Médiane (Q1, Q3)	72,2 (60,4, 85,2)	70,0 (58,3, 82,9)	75,3 (64,1, 87,9)
Probabilité de survie à 60 jours, %, Médiane (Q1, Q3)	0,63 (0,47, 0,74)	0,64 (0,49, 0,76)	0,60 (0,45, 0,72)
DASI, Médiane (Q1, Q3)	19,7 (16,1, 23,4)	19,7 (15,7, 23,5)	19,9 (16,7, 23,4)
Score APACHE III, Médiane (Q1, Q3)	54,0 (41,0, 67,0)	50,0 (38,0, 62,0)	60,0 (47,0, 74,0)
Score de Glasgow, Médiane (Q1, Q3)	15,0 (10,1, 15,0)	15,0 (10,1, 15,0)	15,0 (10,6, 15,0)
Bilirubinémie, µM, Médiane (Q1, Q3)	17,3 (13,7, 23,9)	17,3 (12,0, 20,5)	17,3 (17,1, 29,1)
Créatininémie, µM, Médiane (Q1, Q3)	132,6 (88,4, 212,2)	114,9 (79,6, 176,8)	159,1 (106,1, 265,2)
Durée d'hospitalisation, jours, Médiane (Q1, Q3)	14,0 (7,0, 25,0)	12,0 (7,0, 22,0)	16,0 (8,0, 31,0)
Durée jusqu'au décès, jours, Médiane (Q1, Q3)	28,0 (8,0, 166,0)	33,0 (9,0, 197,0)	23,0 (7,0, 118,0)
Q1 : 1er quartile ; Q3 : 3e quartile.			

4 Score de propension

Dans la décision de procéder ou non à un cathétérisme droit, il a pu être à l'oeuvre un **biais d'indication** : comme semblait le montrer l'analyse bivariée, certains sujets pouvaient avoir des caractéristiques les rendant plus susceptibles de subir

l'intervention, ce qui pouvait fausser les comparaisons entre groupes traités et non traités et mener à des conclusions erronées sur son efficacité.

Un **score de propension** a été créé dans le but de minimiser ce biais potentiel, en permettant d'évaluer l'efficacité du cathétérisme dans une situation où tous les sujets avaient la même probabilité de subir le geste.

4.1 Imputation des données manquantes

Pour rappel, les variables suivantes comportaient des valeurs manquantes dans des proportions jugées raisonnables :

variable	label	n_miss	p_miss
weight	Poids, kg	515	9,0%
pv_pam	Pression artérielle moyenne, mmHg	80	1,4%
pv_fc	Fréquence cardiaque, bpm	159	2,8%
pv_fr	Fréquence respiratoire, rpm	136	2,4%
tt_discharge	Durée d'hospitalisation, jours	1	0,0%

Celles-ci ont toutes été traitées par **imputations multiples** en suivant la méthode des **forêts aléatoires** (10 imputations, 5 itérations).

```r
.init <- mice(df_setup, maxit = 0)

.method <- .init$method
.method[.miss_data$variable] <- "rf"
.method["tt_death"] <- ""

.predictors <- .init$predictorMatrix
.predictors[, "tt_death"] <- 0

df_imp <-
df_setup |>
  mice(m = 10,
       maxit = 5,
       predictorMatrix = .predictors,
       method = .method) |>
  complete() |>
  as_tibble()

# save(df_imp, file = "data/df_imp.rdata")
```

4.2 Description du modèle

Un modèle régression logistique a été réalisé afin de prédire la propension à subir un cathétérisme droit (variable `rhc`) en fonction des **30 variables prédictives** suivantes :

	variable	label
1	sex	Sexe
2	weight	Poids, kg
3	cancer	Cancer

	variable	label
4	ethnic	Origine ethnique
5	educ	Niveau d'études, grade
6	income	Revenu, k$
7	insur	Assurance maladie
8	transfer	Transfert interhospitalier >24h
9	proba_surv	Probabilité de survie à 60 jours, %
10	dnr	Limitation/arrêt des thérapeutiques actives
11	score_dasi	DASI
12	score_apa	Score APACHE III
13	score_gcs	Score de Glasgow
14	pv_temp	Température, °C
15	pv_pam	Pression artérielle moyenne, mmHg
16	pv_fc	Fréquence cardiaque, bpm
17	pv_fr	Fréquence respiratoire, rpm
18	pv_paco2	PaCO2, mmHg
19	pv_pafi	PaO2/FiO2, mmHg
20	pv_ph	pH
21	bio_leuco	Leucocytémie, G/L
22	bio_bili	Bilirubinémie, μM
23	bio_creat	Créatininémie, μM
24	bio_sodium	Natrémie, mM
25	bio_kalium	Kaliémie, mM
26	bio_hema	Hématocrite, %
27	org_fail	Défaillance d'organe
28	age_cat	Âge, années
29	n_diag	Nb. de diagnostics à l'admission
30	n_comorb	Nb. de comorbidités

La distribution du score de propension dans l'ensemble de la population était la suivante :

Caractéristique	Min	Q1	Médiane	Q3	Max	Moyenne±SD
Score de propension	0,01	0,20	0,35	0,54	0,98	0,38±0,22

La distribution du score de propension dans chaque groupe était la suivante :

::: {add-from=/home/julien/Documents/pro/m2/m2_dm3/scripts/fig_dist.R code-line-numbers=‹ true › code-file-name=fig_dist.R (1)}

```

```

:::

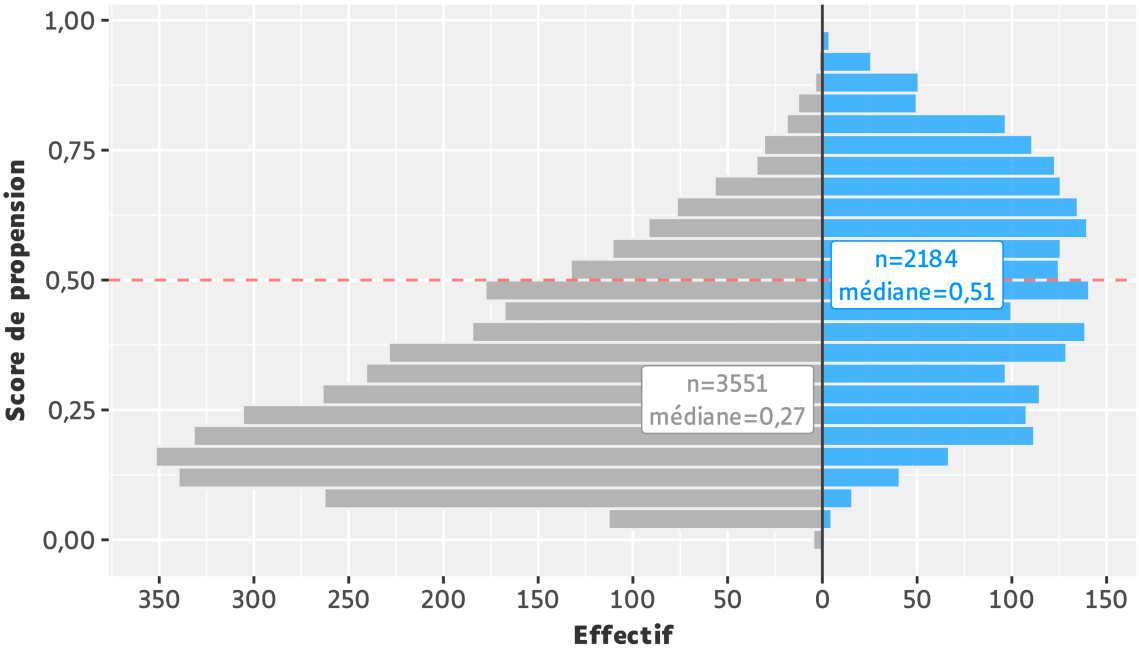

Figure 5. – Distribution du score de propension chez les sujets **sans** et **avec** cathétérisme droit.

Dans une situation où le score de propension prédirait parfaitement l'allocation du cathétérisme, il n'y aurait aucune observation située au-dessus de la ligne horizontale chez les sujets sans et aucune située en dessous chez les sujets avec.

Dans le cas présent, parmi les sujets sans cathétérisme, une faible proportion était considérée éligible à tord. Le modèle prédisait efficacement la non-allocution du cathétérisme chez les sujets ne l'ayant effectivement pas subi, ce qui laissait supposer d'une **bonne spécificité**.

Parmi les sujets avec cathétérisme, le modèle ne semblait pas capable de déterminer la propension des sujets à subir le geste. Autrement dit le modèle prédisait mal l'allocution du cathétérisme chez les sujets l'ayant effectivement subi, ce qui laissait supposer d'une **faible sensibilité**.

4.3 Performances du modèle

Les performances supposées du score de propension ont pu être évaluées à l'aide d'une **courbe ROC**.

```
fig_roc <-
df_sp |>
  roc_curve(.pred_0, truth = rhc) |>
  ggplot() +
  aes(x = 1 - specificity,
      y = sensitivity) +
  geom_line(alpha = 0.7) +
  geom_text(data = df_sp |> roc_auc(.pred_0, truth = rhc),
            mapping = aes(label = glue("AUC={round(.estimate, 2)}")),
            x = 0.2, y = 0.85,
            size = 4,
            family = opts$font) +
```

```
  annotation_custom(grob =
                      df_sp |>
                        conf_mat(.pred_class, truth = rhc) |>
                        autoplot(type = "heatmap") |>
                        ggplotGrob(),
                    xmin = 0.47, xmax = 1.05,
                    ymin = -0.05, ymax = 0.55) +
  list(geom_abline(!!!opts$line),
       geom_hline(yintercept = 1, !!!opts$line),
       geom_vline(xintercept = 0, !!!opts$line)) |>
  inject() +
  coord_equal() +
  labs(x = "Non-spécificité",
       y = "Sensibilité") +
  theme_bar(grid = FALSE)

easy_out(fig_roc, size = c(4, 4))
```

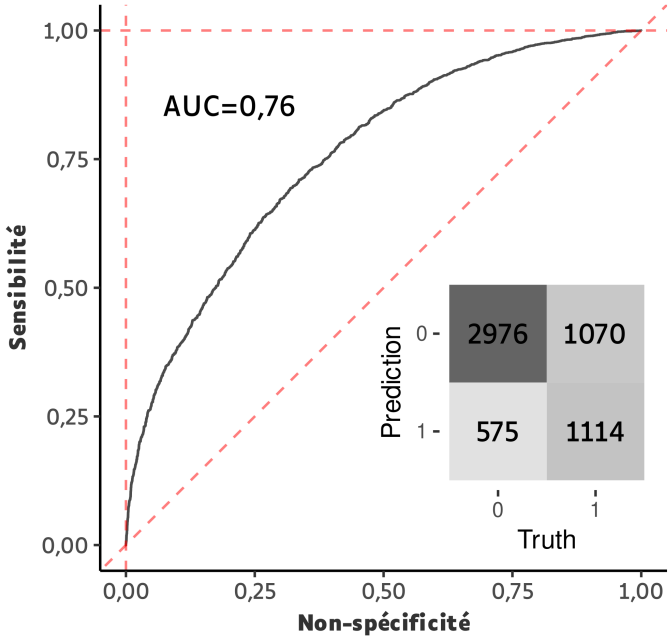

Figure 6. – Courbe ROC du score de propension pour la classification du cathétérisme droit.

Une telle aire sous la courbe témoignait d'une capacité discriminante **faible à modérée**.

Les **paramètres intrinsèques** ont pu être calculés :

- Sensibilité = 2976 / 3551 = **51,0%**
- Spécificité = 1114 / 2184 = **83,8%**

4.4 Appariement

Les sujets ont été appariés sur le score de propension selon un ratio **1:1**, par la méthode des plus proches voisins. Un caliper fixé à **0,002** (0,01 * 0.2) semblait être un bon compromis entre qualité de l'appariement et préservation de la puissance.

::: {add-from=/home/julien/Documents/pro/m2/m2_dm3/scripts/fig_dist.R code-line-numbers=‹ true › code-file-name=fig_dist.R (2)}

```

```

:::

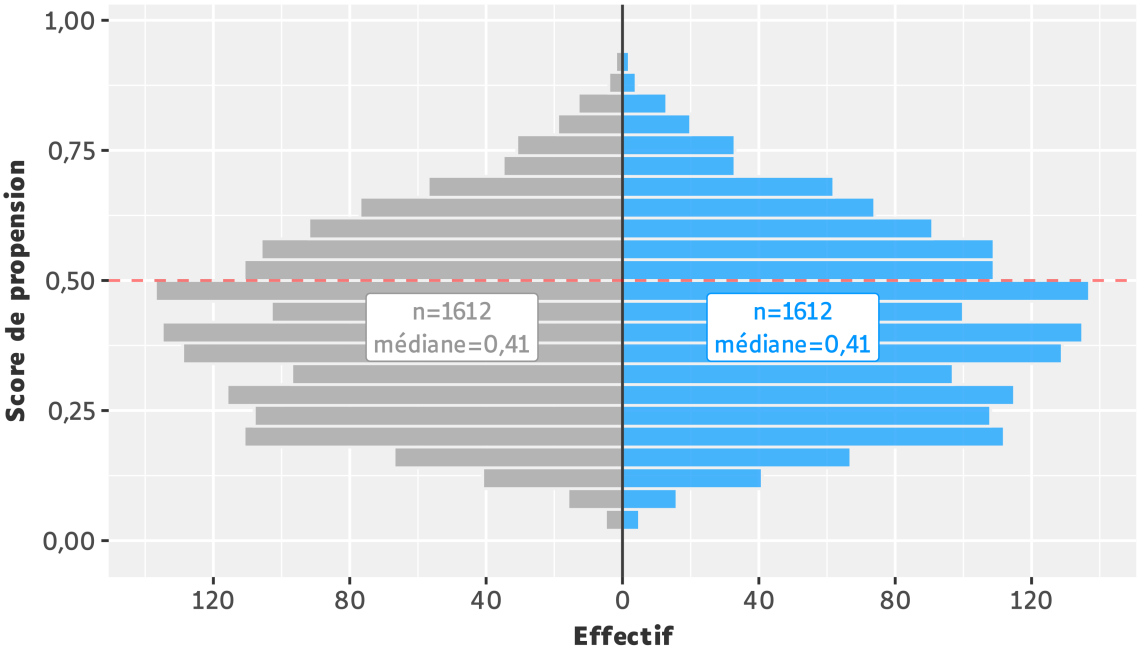

Figure 7. – Distribution du score de propension après appariement entre les sujets **sans** et **avec** cathétérisme droit. Appariement 1:1 selon la méthode des plus proches voisins. Caliper fixé à 0,002 (brut). 1612 appariements réalisés sur 2184 possibles, soit avec une correspondance de 73.8%.

L'appariement semblait visuellement satisfaisant.

Le jeu de données apparié était ainsi constitué de (1612 x 2) / 5735 = **56,2%** du jeu de données initial. L'équilibrage des variables entre les groupes pouvait être évalué par le calcul des **différences moyennes standardisées**.

```
fig_smd <-
compar_df |>
  imap(~ tidy_smd(.df = .x,
                  .vars = all_of(sp_vars),
                  .group = rhc) |>
         mutate(smd = abs(smd),
                group = .y)) |>
  list_c() |>
  ggplot() +
  aes(x = smd,
      y = reorder(variable, smd)) +
  list(geom_vline(xintercept = 0, !!!opts$line[-1]),
       geom_vline(xintercept = 0.1, !!!opts$line)) |>
  inject() +
  geom_line(color = opts$palette[2],
            linewidth = 0.3) +
  geom_point(aes(color = group)) +
  labs(x = "SMD",
       y = "Variable") +
  scale_color_manual(values = rev(opts$palette)) +
  theme_bar(grid = FALSE)

easy_out(fig_smd, size = c(6.5, 5))
```

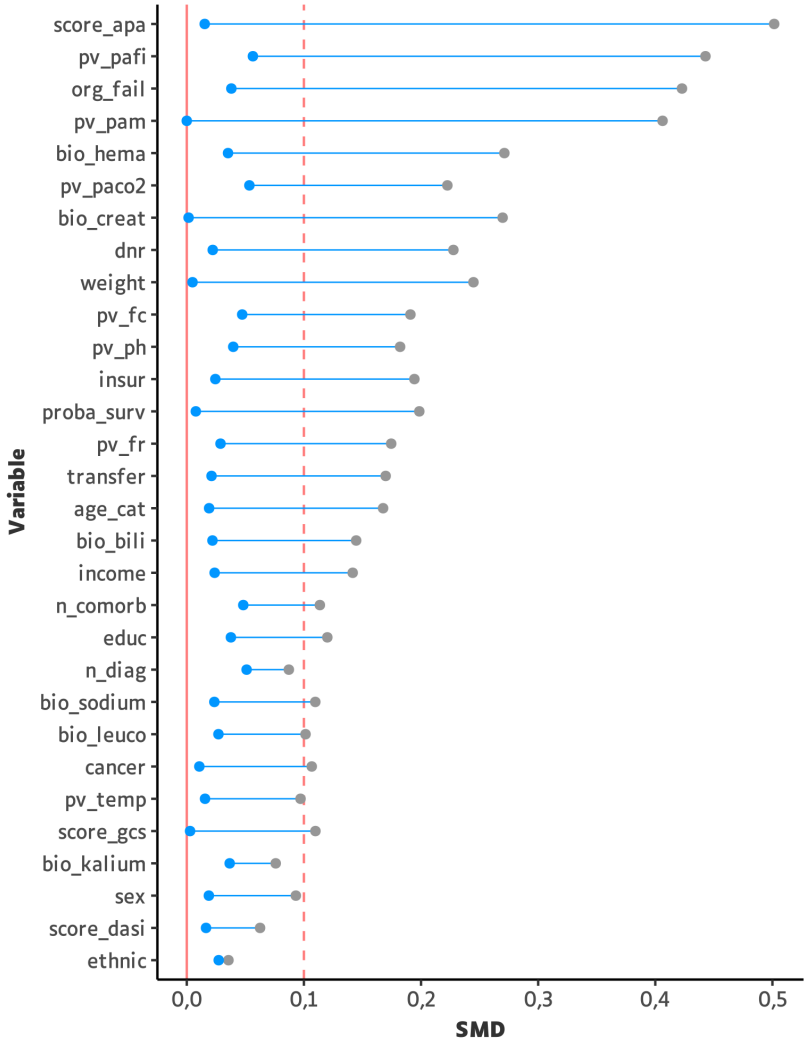

Figure 8. – Différences moyennes standardisées (SMD) pour chaque variable constitutive du score de propension, avant et après appariement. 1612 appariements sur le score propension selon un caliper fixé à 0,002 (brut). Les SMD étaient présentées en valeurs absolues et classées par valeurs globales décroissantes.

L'équilibrage entre les groupes après appariement sur le score de propension n'était pas parfait mais néanmoins considéré satisfaisant.

5 Mortalité à 30 jours

L'objectif était de comparer la mortalité à 30 jours entre les groupes avec et sans cathétérisme droit.

Un **ajustement** sur le score de propension permettait de se placer dans une situation où l'allocation du cathétérisme serait non pas influencée par les caractéristiques du sujet, mais le plus possible **attribuable au hasard** à la manière d'une randomisation.

Dans une telle situation, il devenait théoriquement acceptable de conclure que s'il persistait une différence entre les groupes malgré cet ajustement, **alors elle serait probablement attribuable au geste**.

Le tableau suivant présente les odds ratios fournis par un modèle de régression logistique expliquant la mortalité à 30 jours en fonction de la présence ou non d'un cathétérisme droit, **avant puis après ajustement** sur le score de propension :

	OR [IC95%]	p.value
non_ajusté	1,39 [1,24 ; 1,55]	<0,001
ajusté	1,17 [1,01 ; 1,36]	0,031

Sans ajustement, le cathétérisme droit était associée à un risque plus élevé de mortalité à 30 jours comparativement aux sujets n'ayant pas subi le geste. Bien qu'elle fut atténuée, cette différence de risque semblait **persister après ajustement**.

L'estimation pouvait sensiblement varier en fonction des paramètres choisis (variables incluses dans le calcul du score de propension, choix du caliper, etc.), mais semblait néanmoins toujours aller dans le sens d'une **diminution**. Ainsi il a été jugé plus pertinent de porter des conclusions non pas sur des chiffres mais plutôt sur une tendance générale.

On pouvait donc retenir de cette analyse que la différence de risque de mortalité à 30 jours entre les groupes avec et sans cathétérisme droit tendait à être **plus faible après ajustement** sur le score de propension.

Cette tendance montrait que le risque de mortalité plus élevé chez les sujets ayant subi un cathétérisme pouvait être au moins en partie attribuable aux **caractéristiques des sujets** avant tout. Quant à l'imputabilité de l'intervention, il paraissait difficile de l'affirmer en l'état.

6 Analyse de survie

Cette tendance pouvait être confirmée à l'aide d'une **analyse time-to-event** ayant pour évènement la **mortalité à 30 jours**.

Une courbe de survie a été produite selon la méthode de Kaplan-Meier, ainsi qu'un modèle de Cox dans le but de quantifier le **risque instantané de décès** entre les groupes avec et sans cathétérisme.

```
fig_surv <- \(x, y) {

  .surv <-
  lst(data =
        mutate(.data = x,
               tt_death = if_else(tt_death >= 30, 30, tt_death, missing = 30)),
      model =
        lst(fit =
              exprs(Surv(tt_death, ev_death_30) ~ rhc, data = data),
            tte =
              lst(obj = do.call("survfit2", fit),
                  tidy =
                    tidy_survfit(obj) |>
                      split(~ strata) |>
                      map(~ . |>
                            unite("n.event/censor", n.event:n.censor,
                                  sep = "/", remove = TRUE) |>
                            unite("cum.event/censor", cum.event:cum.censor,
                                  sep = "/", remove = TRUE) |>
                            merge_estim_ci(ci_data = opts$ci$data) |>
                            select(time, starts_with(c("n", "cum")), estimate_ci))),
            cox =
              lst(obj = do.call("coxph", fit),
                  tidy =
                    tidy(obj,
                         exponentiate = TRUE,
                         conf.int = TRUE) |>
                      merge_estim_ci(ci_data = opts$ci$data) |>
                      mutate(str = "Hazard ratio pour le décès",
                             p.value = style_pvalue(p.value, prepend_p = TRUE)))))

  .fig <-
  .surv$model$tte$obj |>
    ggsurvfit() +
    add_risktable(risktable_stats = c("{n.risk} ({cum.event})"),
                  stats_label = list("{n.risk} ({cum.event})" = "No. at Risk (Events)"),
                  risktable_group = "risktable_stats",
                  size = 2,
```

```
                  family = opts$font,
                  theme = theme_risktable(plot_margin = 5)) +
    add_risktable_strata_symbol(symbol = "\U2014", size = 8) +
    geom_text(data = .surv$model$cox$tidy,
              mapping =
                aes(label =
                      glue("{str} {opts$ci$label}{opts$sep$int}{estimate_ci}
                           Log rank {p.value}"),
                    x = 30,
                    y = 1),
              size = 2.25,
              hjust = 1,
              vjust = 1,
              family = opts$font) +
    scale_color_manual(values = opts$palette) +
    scale_ggsurvfit(x_scales =
                      list(name = "Durée jusqu'au décès (jours)",
                           breaks = seq(0, 30, by = 5),
                           expand = expansion(mult = 0.05)),
                    y_scales =
                      list(name = "Probabilité de survie (%)",
                           labels = style_percent,
                           breaks = seq(0, 1, by = 0.2))) +
    theme_tte()

}

imap(compar_df, fig_surv) |>
  easy_out_map(
    filename = "fig_surv",
    size = c(3.25, 6)
  )
```

7 Sans ajustement

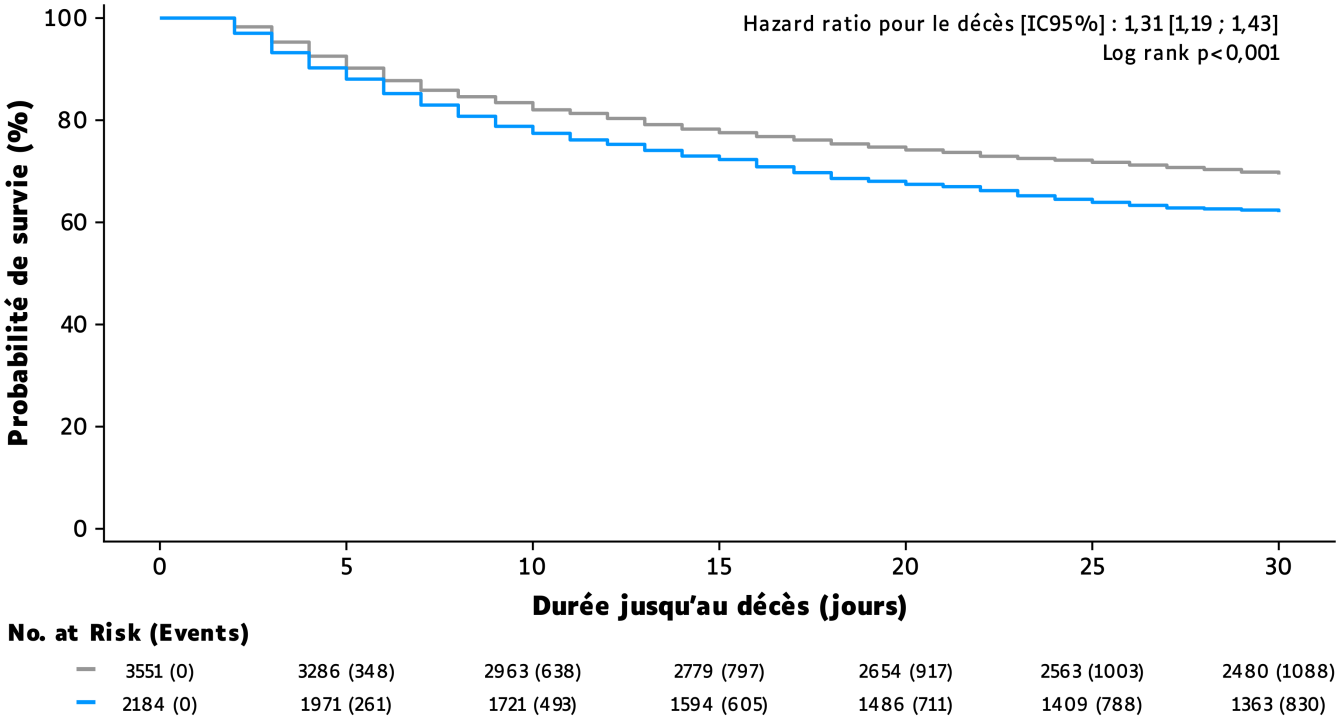

Figure 9. – Comparaison du risque de mortalité à 30 jours entre les sujets **sans** et **avec** cathétérisme droit, sans ajustement. Les courbes étaient construites suivant la méthode de Kaplan-Meier. Aucune censure n'était observée avant la date de point.

8 Après ajustement

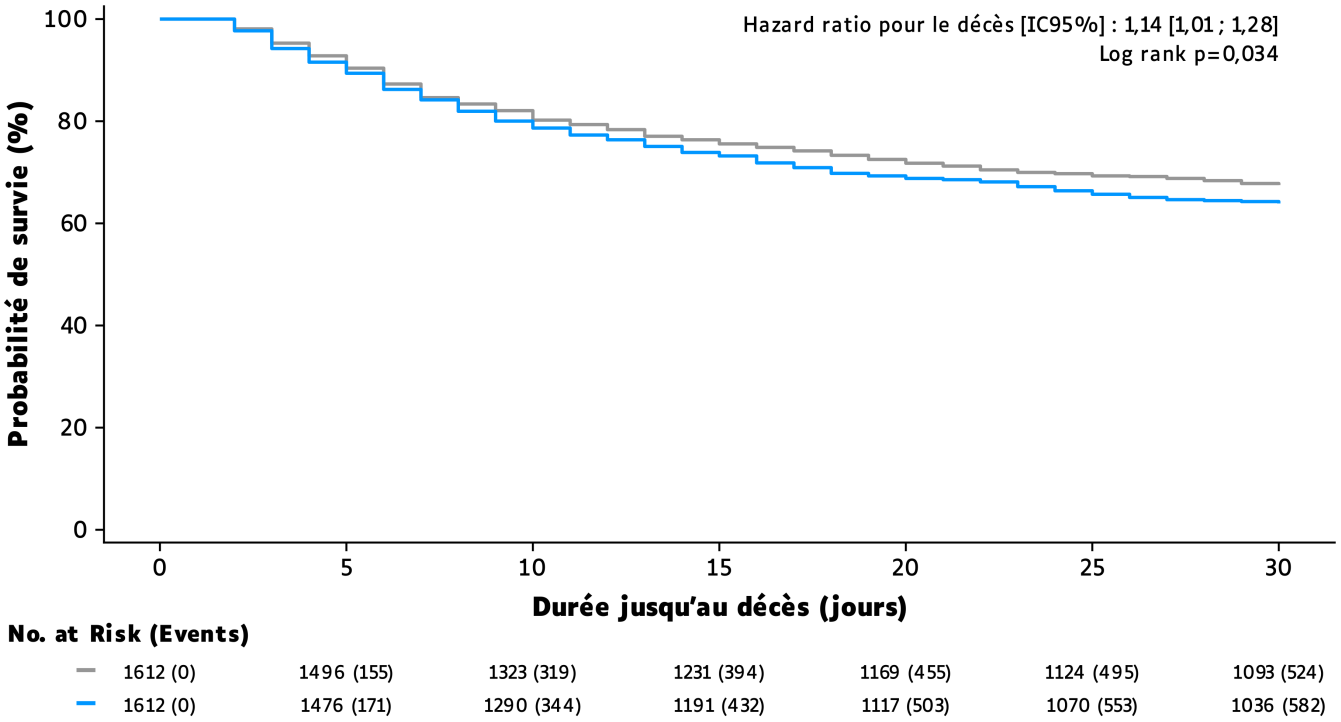

Figure 10. – Comparaison du risque de mortalité à 30 jours entre les sujets **sans** et **avec** cathétérisme droit, après ajustement. Les courbes étaient construites suivant la méthode de Kaplan-Meier. Aucune censure n'était observée avant la date de point.

Sans ajustement sur le score de propension, le groupe avec cathétérisme présentait un risque **significativement plus élevé** de mortalité à 30 jours comparé au groupe sans cathétérisme.

Après ajustement sur le score de propension, la différence de risque entre les groupes était **plus faible**.

9 Conclusion

Le cathétérisme droit dans les 24h suivant une admission en soins intensifs était associé à un **risque plus élevé de mortalité à 30 jours**, comparativement aux sujets n'ayant pas subi l'intervention. Une différence de risque entre les groupes **plus faible après ajustement** sur le score de propension révélait qu'un **biais d'indication** était probablement à l'oeuvre.

La nature **observationnelle** de l'étude, le **choix des variables** incluses dans le calcul du score de propension, la **perte de puissance** induite par l'appariement, étaient des facteurs limitant l'interprétabilité des résultats. Un **essai randomisé** permettrait de porter de meilleures conclusions quant à l'imputabilité du cathétérisme droit sur la mortalité à 30 jours.

Session

```
#> ─ Session info ───────────────────────────────────────────────────────────────
#>  setting  value
#>  version  R version 4.5.2 (2025-10-31)
#>  os       Ubuntu 24.04.3 LTS
#>  system   x86_64, linux-gnu
#>  ui       X11
#>  language (EN)
#>  collate  fr_FR.UTF-8
#>  ctype    fr_FR.UTF-8
#>  tz       Europe/Paris
#>  date     2025-11-30
#>  pandoc   3.6.3 @ /usr/share/positron/resources/app/quarto/bin/tools/x86_64/ (via rmarkdown)
#>  quarto   1.7.31 @ /opt/quarto/bin/quarto
#>
#> ─ Packages ───────────────────────────────────────────────────────────────────
#>  ! package      * version    date (UTC) lib source
#>  P broom        * 1.0.10     2025-09-13 [?] CRAN (R 4.5.1)
#>  P dials        * 1.4.2      2025-09-04 [?] CRAN (R 4.5.1)
#>  P dplyr        * 1.1.4      2023-11-17 [?] CRAN (R 4.5.0)
#>  P forcats      * 1.0.1      2025-09-25 [?] CRAN (R 4.5.1)
#>  P ggplot2      * 4.0.1      2025-11-14 [?] CRAN (R 4.5.2)
#>  P ggsurvfit    * 1.2.0      2025-09-13 [?] CRAN (R 4.5.2)
#>  P glue         * 1.8.0      2024-09-30 [?] CRAN (R 4.5.0)
#>  P gt           * 1.1.0      2025-09-23 [?] CRAN (R 4.5.1)
#>  P gtsummary    * 2.4.0      2025-08-28 [?] CRAN (R 4.5.2)
#>  P halfmoon     * 0.1.0.9000 2025-11-29 [?] Github (r-causal/halfmoon@7e0193f)
#>  P hebstr       * 0.0.0.9000 2025-11-29 [?] local
#>  P infer        * 1.0.9      2025-06-26 [?] CRAN (R 4.5.1)
#>  P knitr        * 1.50       2025-03-16 [?] CRAN (R 4.5.0)
#>  P labelled     * 2.16.0     2025-10-22 [?] CRAN (R 4.5.2)
#>  P lubridate    * 1.9.4      2024-12-08 [?] CRAN (R 4.5.0)
#>  P MatchIt      * 4.7.2      2025-05-30 [?] CRAN (R 4.5.2)
#>  P mice         * 3.18.0     2025-05-27 [?] CRAN (R 4.5.2)
#>  P modeldata    * 1.5.1      2025-08-22 [?] CRAN (R 4.5.1)
#>  P parsnip      * 1.3.3      2025-08-31 [?] CRAN (R 4.5.1)
#>  P patchwork    * 1.3.2      2025-08-25 [?] CRAN (R 4.5.1)
#>  P purrr        * 1.2.0      2025-11-04 [?] CRAN (R 4.5.2)
#>  P readr        * 2.1.6      2025-11-14 [?] CRAN (R 4.5.2)
#>  P recipes      * 1.3.1      2025-05-21 [?] CRAN (R 4.5.0)
#>  P rlang        * 1.1.6      2025-04-11 [?] CRAN (R 4.5.0)
#>  P rsample      * 1.3.1      2025-07-29 [?] CRAN (R 4.5.1)
```

```
#>  P scales       * 1.4.0      2025-04-24 [?] CRAN (R 4.5.0)
#>  P stringr      * 1.6.0      2025-11-04 [?] CRAN (R 4.5.2)
#>  P survival     * 3.8-3      2024-12-17 [?] CRAN (R 4.4.2)
#>  P tailor       * 0.1.0      2025-08-25 [?] CRAN (R 4.5.1)
#>  P tibble       * 3.3.0      2025-06-08 [?] CRAN (R 4.5.1)
#>  P tidymodels   * 1.4.1      2025-09-08 [?] CRAN (R 4.5.1)
#>  P tidyr        * 1.3.1      2024-01-24 [?] CRAN (R 4.5.0)
#>  P tidyverse    * 2.0.0      2023-02-22 [?] CRAN (R 4.5.0)
#>  P tune         * 2.0.1      2025-10-17 [?] CRAN (R 4.5.1)
#>  P workflows    * 1.3.0      2025-08-27 [?] CRAN (R 4.5.1)
#>  P workflowsets * 1.1.1      2025-05-27 [?] CRAN (R 4.5.0)
#>  P yardstick    * 1.3.2      2025-01-22 [?] CRAN (R 4.5.0)
#>
#>  [1] /home/julien/Documents/pro/m2/m2_dm3/renv/library/linux-ubuntu-noble/R-4.5/x86_64-pc-
linux-gnu
#>  [2] /home/julien/.cache/R/renv/sandbox/linux-ubuntu-noble/R-4.5/x86_64-pc-linux-gnu/9a444a72
#>
#>  * ── Packages attached to the search path.
#>  P ── Loaded and on-disk path mismatch.
#>
#> ──────────────────────────────────────────────────────────────────────────────
```